

Analyse et Prédiction des Tremblements de Terre

Approche par Machine Learning

Contexte du projet

Les tremblements de terre représentent un risque naturel majeur pouvant causer des pertes humaines et matérielles importantes. Malgré les progrès scientifiques, leur prédiction reste un défi complexe. Dans ce contexte, l'objectif de ce projet est d'exploiter les données historiques des séismes (USGS Earthquake Dataset) afin d'identifier des patterns et d'utiliser des techniques de Machine Learning pour analyser et éventuellement prédire la magnitude ou classer les niveaux de risque.

Source des données : USGS Earthquake Database (Kaggle)

Lien : <https://www.kaggle.com/datasets/usgs/earthquake-database>

Projet de Machine Learning

Encadré par : Ben Lahmar El Habib - Omaila Gndou

Réalisé par : Hasnae Amejoud - Meriem Berrima

Année Universitaire : 2025/2026

Table des matières

Remerciements	4
Résumé	5
Abstract	6
Introduction Générale	7
1 Contexte et état de l'art	9
1.1 Introduction	9
1.2 Présentation des tremblements de terre	9
1.3 Notions de sismologie	10
1.4 Impact des séismes dans le monde	10
1.5 Intelligence artificielle et Machine Learning	11
1.6 Travaux de recherche existants	12
1.7 Diagramme de Gantt du projet	12
1.8 Conclusion	13
2 Présentation des données	14
2.1 Introduction	14
2.2 Présentation du dataset USGS	14
2.3 Description des variables	14
2.4 Collecte des données	15
2.5 Analyse exploratoire des données (EDA)	15
2.6 Visualisations statistiques	16
2.7 Analyse géographique des séismes	18
2.8 Conclusion	19
3 Prétraitement et Feature Engineering	21
3.1 Introduction	21
3.2 Nettoyage des données	21
3.3 Gestion des valeurs manquantes	21
3.4 Suppression des doublons	22
3.5 Traitement des outliers	22
3.6 Transformation des variables	22
3.7 Extraction des variables temporelles	23
3.8 Création de variables dérivées	23
3.9 Création des classes de magnitude	23
3.10 Encodage des variables catégorielles	24
3.11 Conclusion	24
4 Modélisation Machine Learning	25
4.1 Introduction	25

4.2	Algorithmes utilisés	25
4.3	Méthodologie d'évaluation	26
4.4	Résultats de la classification	26
4.5	Résultats de la régression	28
4.6	Importance des variables	29
4.7	Visualisation SHAP	30
4.8	Conclusion	30
5	Interprétabilité et Dashboard Interactif	32
5.1	Introduction	32
5.2	Interprétabilité des modèles	32
5.3	Dashboard Interactif	33
5.4	Limites et perspectives d'amélioration	36
5.5	Conclusion	37
	Conclusion Générale	38
	Bibliographie	40

Table des figures

1.1	Diagramme de Gantt	13
2.1	Répartition des séismes par profondeur	16
2.2	Distribution des magnitudes par classe	17
2.3	Profondeur vs Classe de magnitude	18
2.4	Nombre de séismes par région géographique	19
2.5	Densité géographique des séismes	20
2.6	Exemple de visualisation d'un séisme (Magnitude=5.6, Latitude=-44.009, Longitude=-15.978)	20
4.1	Comparaison visuelle des métriques par modèle	27
4.2	Matrice de confusion du modèle LightGBM	28
4.3	Valeurs réelles vs prédites (XGBoost Regressor, n=1000)	28
4.4	Distribution des résidus de prédiction	29
4.5	Importance des variables dans le modèle LightGBM	30
4.6	Valeurs SHAP pour l'interprétabilité du modèle	31
5.1	Tableau de bord principal	34
5.2	Paramètres temporels et résultats	34
5.3	Carte de localisation	35

Remerciements

Au terme de ce projet de fin d'études, nous tenons à exprimer notre profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce travail.

Nous adressons nos plus vifs remerciements à nos encadrants, **Monsieur Ben Lahmar El Habib** et **Madame Omaïma Gndou**, pour leur encadrement exceptionnel, leurs conseils avisés, leur disponibilité et leur patience tout au long de ce projet. Leurs expertises et leurs orientations précieuses ont été déterminantes pour la réussite de ce travail.

Nous tenons également à remercier l'ensemble du corps professoral et administratif de la **Faculté des Sciences Ben M'sick (FSBM)** pour la qualité de l'enseignement dispensé tout au long de notre parcours universitaire. Leurs connaissances transmises avec passion ont été le socle de notre formation.

Nos remerciements vont aussi aux membres du jury qui nous ont fait l'honneur d'évaluer ce travail. Leurs critiques constructives et leurs suggestions permettront d'enrichir davantage cette étude.

Nous n'oublions pas nos familles et amis pour leur soutien moral inconditionnel, leurs encouragements constants et leur patience durant cette période intense de travail.

Enfin, nous remercions toutes les personnes qui ont contribué directement ou indirectement à la réalisation de ce projet.

Résumé

Les tremblements de terre représentent l'un des risques naturels les plus dévastateurs à l'échelle mondiale, causant chaque année des milliers de victimes et des dégâts matériels considérables. Face à ce constat, la prédiction sismique demeure un défi scientifique majeur en raison de la complexité des processus géophysiques impliqués.

Ce projet vise à exploiter le *USGS Earthquake Dataset*, une base de données historique complète des séismes mondiaux, pour développer des modèles prédictifs basés sur des techniques avancées de **Machine Learning**. Notre approche méthodologique s'articule autour de plusieurs étapes fondamentales : une analyse exploratoire approfondie des données (EDA), un prétraitement rigoureux incluant le nettoyage et l'ingénierie des fonctionnalités, et le développement de modèles de classification et de régression.

Les résultats obtenus sont particulièrement prometteurs. Pour la tâche de classification des niveaux de risque sismique, le modèle **LightGBM** (Light Gradient Boosting Machine) atteint une précision exceptionnelle de **97.99%**, surpassant les autres algorithmes testés tels que XGBoost (97.31%), Random Forest (93.44%) et la régression logistique (92.08%). Pour la prédiction de magnitude, le **XGBoost Regressor** démontre d'excellentes performances avec une forte corrélation entre les valeurs réelles et prédites.

L'analyse de l'importance des variables révèle que la profondeur du séisme (*depth*), le ratio de profondeur (*depth_ratio*) et la distance au centre géographique sont les facteurs les plus influents dans la prédiction de la magnitude. Ces résultats sont cohérents avec les connaissances sismologiques établies.

Enfin, un **dashboard interactif** a été développé pour rendre ces modèles accessibles aux utilisateurs non-experts, permettant la saisie de paramètres sismiques et la visualisation en temps réel des prédictions. Cet outil constitue une contribution concrète à l'aide à la décision dans le domaine de la gestion des risques sismiques.

Mots-clés : Machine Learning, Séismes, USGS Earthquake Dataset, LightGBM, XGBoost, Classification des risques, Prédiction de magnitude, Analyse exploratoire des données (EDA), Dashboard interactif, Interprétabilité des modèles.

Abstract

Earthquakes represent one of the most devastating natural hazards worldwide, causing thousands of casualties and considerable material damage each year. Given this situation, seismic prediction remains a major scientific challenge due to the complexity of the underlying geophysical processes.

This project aims to leverage the *USGS Earthquake Dataset*, a comprehensive historical database of global earthquakes, to develop predictive models based on advanced **Machine Learning** techniques. Our methodological approach consists of several fundamental steps : thorough exploratory data analysis (EDA), rigorous preprocessing including data cleaning and feature engineering, and development of classification and regression models.

The results obtained are particularly promising. For the seismic risk level classification task, the **LightGBM** (Light Gradient Boosting Machine) model achieves an exceptional accuracy of **97.99%**, outperforming other tested algorithms such as XGBoost (97.31%), Random Forest (93.44%), and Logistic Regression (92.08%). For magnitude prediction, the **XGBoost Regressor** demonstrates excellent performance with a strong correlation between actual and predicted values.

Feature importance analysis reveals that earthquake depth (*depth*), depth ratio (*depth_ratio*), and distance to geographic center are the most influential factors in magnitude prediction. These results are consistent with established seismological knowledge.

Finally, an **interactive dashboard** has been developed to make these models accessible to non-expert users, allowing the input of seismic parameters and real-time visualization of predictions. This tool represents a concrete contribution to decision support in the field of seismic risk management.

Keywords : Machine Learning, Earthquakes, USGS Earthquake Dataset, LightGBM, XGBoost, Risk Classification, Magnitude Prediction, Exploratory Data Analysis (EDA), Interactive Dashboard, Model Interpretability.

Introduction Générale

Contexte et problématique

Les tremblements de terre constituent l'un des phénomènes naturels les plus imprévisibles et destructeurs à l'échelle planétaire. Chaque année, ces événements sismiques causent des milliers de victimes et des dégâts matériels colossaux, mettant en péril des infrastructures vitales et des communautés entières. Les récents séismes en Turquie et Syrie (février 2023), ayant fait plus de 50,000 victimes, rappellent tragiquement la vulnérabilité des populations face à ces catastrophes naturelles.

Malgré les avancées considérables réalisées en sismologie au cours des dernières décennies, la prédiction exacte du moment, du lieu et de l'intensité d'un séisme reste un défi scientifique majeur. Cette difficulté s'explique par la complexité des processus géophysiques en jeu et la nature non linéaire des phénomènes tectoniques.

Cependant, l'avènement de l'ère du *Big Data* et des technologies numériques offre une nouvelle perspective prometteuse. L'accumulation massive de données historiques sur les séismes, enregistrées par des organismes de surveillance tels que l'*United States Geological Survey* (USGS), représente une mine d'informations inexploitées. L'hypothèse centrale de ce travail est que l'application de techniques avancées d'Intelligence Artificielle et de **Machine Learning** à ces données pourrait permettre d'identifier des motifs (patterns) récurrents, d'affiner l'évaluation des risques et, dans une certaine mesure, d'améliorer les capacités prédictives.

Objectifs du projet

Ce projet s'inscrit dans cette perspective et vise plusieurs objectifs complémentaires :

1. **Analyser les caractéristiques des séismes passés** : Comprendre la distribution spatiale, temporelle et statistique des tremblements de terre à travers le monde.
2. **Développer des modèles prédictifs de magnitude** : Créer des algorithmes de régression capables d'estimer la magnitude d'un séisme en fonction de paramètres géographiques et temporels.
3. **Classifier les niveaux de risque sismique** : Concevoir des modèles de classification pour catégoriser les séismes selon leur intensité (Moyen, Fort, Majeur).
4. **Créer un dashboard interactif** : Développer une interface utilisateur permettant la visualisation et l'exploitation des résultats de manière accessible.

Méthodologie adoptée

Pour atteindre ces objectifs, nous avons adopté une démarche méthodologique rigoureuse, propre aux projets de *Data Science*, qui s'articule autour des étapes suivantes :

- **Collecte et exploration des données** : Analyse approfondie du dataset USGS pour comprendre sa structure et ses caractéristiques.
- **Prétraitement et Feature Engineering** : Nettoyage des données, gestion des valeurs manquantes, création de variables pertinentes.
- **Modélisation Machine Learning** : Développement et comparaison de plusieurs algorithmes de classification et de régression.
- **Évaluation et interprétabilité** : Analyse des performances des modèles et compréhension des facteurs influents.
- **Déploiement** : Création d'un dashboard interactif pour la mise à disposition des résultats.

Structure du rapport

Ce rapport est organisé en six chapitres principaux :

- Le **Chapitre 1** pose le cadre théorique en présentant les notions de sismologie, l'impact des séismes, ainsi que l'état de l'art du Machine Learning appliqué à ce domaine.
- Le **Chapitre 2** est consacré à la présentation du dataset USGS et à l'analyse exploratoire des données (EDA), incluant des visualisations statistiques et géographiques.
- Le **Chapitre 3** détaille les étapes de prétraitement, de nettoyage et de *Feature Engineering* appliquées aux données.
- Le **Chapitre 4** expose la démarche de modélisation, le choix des algorithmes, leur évaluation comparative et l'analyse de l'importance des variables.
- Le **Chapitre 5** se concentre sur l'interprétabilité des modèles et les résultats de régression pour la prédiction de magnitude.
- Le **Chapitre 6** présente le développement et les fonctionnalités du dashboard interactif conçu pour visualiser les insights du projet.

Ce document retrace ainsi l'ensemble du processus, de la collecte des données brutes jusqu'à la mise à disposition d'un outil d'aide à la décision, illustrant la valeur ajoutée du Machine Learning dans l'analyse des risques naturels.

Chapitre 1

Contexte et état de l'art

1.1 Introduction

Ce premier chapitre a pour objectif de poser les fondements théoriques et contextuels de notre projet. Nous y définirons d'abord le phénomène des tremblements de terre et les notions essentielles de sismologie nécessaires à la compréhension des données. Ensuite, nous aborderons l'impact mondial de ces catastrophes naturelles, ce qui justifie l'urgence et l'utilité de notre étude. Nous introduirons également les concepts d'Intelligence Artificielle et de Machine Learning, en expliquant leur pertinence dans l'analyse sismique. Enfin, nous dresserons un état de l'art des travaux de recherche existants avant de présenter le planning prévisionnel de notre projet.

1.2 Présentation des tremblements de terre

Un tremblement de terre, ou séisme, est une manifestation de la libération soudaine d'énergie accumulée dans la croûte terrestre. Cette énergie se propage sous forme d'ondes sismiques qui se diffusent dans toutes les directions à partir du point de rupture.

Origines des séismes

Les séismes trouvent principalement leur origine dans les mouvements des plaques tectoniques qui composent la lithosphère terrestre. Ces plaques, animées par les courants de convection du manteau, sont en mouvement constant les unes par rapport aux autres. Trois types de interactions peuvent se produire :

- **Convergence** : Deux plaques se rapprochent, l'une pouvant plonger sous l'autre (subduction)
- **Divergence** : Deux plaques s'écartent l'une de l'autre
- **Coulissage** : Deux plaques glissent latéralement l'une contre l'autre

Lorsque ces plaques interagissent, des contraintes s'accumulent au niveau des failles géologiques. Lorsque la résistance des roches est dépassée, une rupture brutale se produit, libérant l'énergie accumulée sous forme de vibrations.

Types de séismes

Bien que la majorité des séismes soient d'origine tectonique, il existe d'autres types de séismes :

- **Séismes volcaniques** : Associés à l'activité magmatique

- **Séismes induits** : Provoqués par l'activité humaine (extraction minière, barrages hydro-électriques, fracturation hydraulique)
- **Effondrements** : Liés à l'effondrement de cavités souterraines

1.3 Notions de sismologie

Pour analyser les données sismiques de manière pertinente, il est indispensable de maîtriser quelques concepts clés de la sismologie :

Foyer et épipcentre

Le **foyer** (ou hypocentre) est le point de départ de la rupture à l'intérieur de la Terre, où l'énergie est initialement libérée. Sa profondeur peut varier de quelques kilomètres à plus de 700 km. L'**épicentre** est la projection verticale du foyer à la surface de la Terre. C'est généralement la zone où les secousses sont ressenties avec le plus de force.

Magnitude

La **magnitude** est une mesure objective de l'énergie libérée par le séisme à sa source. Elle est le plus souvent exprimée selon l'échelle de Richter (magnitude locale M_L) ou, plus précisément pour les grands séismes, selon la magnitude de moment (M_w).

Il est important de noter qu'il s'agit d'une **échelle logarithmique** : une augmentation d'une unité de magnitude correspond à une multiplication par environ 32 de l'énergie libérée. Ainsi, un séisme de magnitude 7 libère environ 32 fois plus d'énergie qu'un séisme de magnitude 6.

Intensité

L'**intensité** est une mesure subjective des effets et des dégâts ressentis en un lieu donné. Elle est évaluée à l'aide d'échelles macrosismiques telles que l'échelle EMS-98 (European Macroseismic Scale) ou l'échelle de Mercalli modifiée. Contrairement à la magnitude, qui est unique pour un séisme donné, l'intensité diminue généralement avec la distance à l'épicentre et varie selon les conditions locales.

Ondes sismiques

Les ondes sismiques se divisent en deux catégories principales :

- **Ondes de volume** :
 - Ondes P (Primaires) : Ondes de compression, les plus rapides (6-8 km/s)
 - Ondes S (Secondaires) : Ondes de cisaillement, plus lentes (3-4 km/s) mais plus destructrices
- **Ondes de surface** :
 - Ondes de Love
 - Ondes de Rayleigh

1.4 Impact des séismes dans le monde

Les séismes figurent parmi les catastrophes naturelles les plus meurtrières et les plus coûteuses. Leurs impacts sont multiples et dévastateurs :

Pertes humaines

L'effondrement des bâtiments et des infrastructures est la cause principale des décès et des blessures. Les séismes survenant dans des zones densément peuplées ou dans des régions où les normes de construction parasismique sont insuffisantes peuvent faire des milliers de victimes.

Dégâts matériels et économiques

Les destructions concernent les routes, les ponts, les réseaux d'eau et d'électricité, les hôpitaux, les écoles et les habitations. Les coûts de reconstruction se chiffrent souvent en milliards de dollars, pesant lourdement sur l'économie des pays touchés.

Effets secondaires

Les séismes peuvent déclencher d'autres catastrophes naturelles :

- **Tsunamis** : Comme au Japon en 2011 (magnitude 9.1), où le tsunami a causé plus de dégâts que le séisme lui-même
- **Glissements de terrain** : Particulièrement dans les régions montagneuses
- **Incendies** : Dus à la rupture des conduites de gaz
- **Inondations** : Provoquées par la rupture de barrages

Exemples récents marquants

- **Haïti (2010)** : Magnitude 7.0, plus de 200,000 victimes
- **Népal (2015)** : Magnitude 7.8, environ 9,000 victimes
- **Turquie et Syrie (2023)** : Magnitude 7.8, plus de 50,000 victimes

Ces exemples rappellent tragiquement la vulnérabilité des populations et la nécessité cruciale d'outils d'évaluation et de prévention des risques plus performants.

1.5 Intelligence artificielle et Machine Learning

Définitions

L'**Intelligence Artificielle** (IA) désigne l'ensemble des théories et techniques mises en œuvre pour réaliser des machines capables de simuler l'intelligence humaine. Le **Machine Learning** (Apprentissage Automatique) en est un sous-domaine fondamental. Il consiste à concevoir des algorithmes capables d'apprendre à partir de données, sans être explicitement programmés pour une tâche spécifique.

Pertinence pour la sismologie

Dans le contexte de la sismologie, le Machine Learning est particulièrement adapté pour plusieurs raisons :

1. **Volume de données** : Les organismes comme l'USGS collectent des téraoctets de données sismiques continues, impossibles à analyser manuellement.
2. **Complexité non linéaire** : Les relations entre les variables sismiques (profondeur, localisation, historique) sont hautement non linéaires, un domaine où les algorithmes comme les Forêts Aléatoires (Random Forest) ou les Réseaux de Neurones surpassent les modèles statistiques classiques.
3. **Tâches cibles variées** : Le ML permet d'aborder deux problèmes principaux :
 - La *régression* : Prédire une valeur continue, comme la magnitude
 - La *classification* : Catégoriser un séisme selon son niveau de risque (faible, modéré, élevé)

1.6 Travaux de recherche existants

L'application du Machine Learning à la prédiction sismique est un domaine de recherche très actif. Plusieurs approches ont été explorées dans la littérature scientifique :

Prédiction temporelle

Certains chercheurs ont utilisé des réseaux de neurones récurrents (RNN), et plus particulièrement des modèles LSTM (Long Short-Term Memory), pour tenter de prédire l'occurrence future de séismes en se basant sur des séries temporelles historiques. Les résultats montrent une capacité à identifier des périodes de forte activité, mais pas une prédiction exacte à l'échelle de quelques jours.

Estimation de la magnitude

Des études ont appliqué des algorithmes de régression (SVR - Support Vector Regression, Random Forest, XGBoost) sur des données de l'USGS pour estimer la magnitude d'un événement en fonction de paramètres précurseurs ou géographiques, obtenant des erreurs quadratiques moyennes (RMSE) de plus en plus faibles.

Classification des risques

D'autres travaux se concentrent sur la cartographie des zones à risque en classifiant les régions géographiques selon leur probabilité de subir un séisme d'une magnitude donnée, en utilisant des techniques d'apprentissage supervisé.

Limites actuelles

Bien que la prédiction déterministe exacte (date, heure, lieu précis) reste un objectif non atteint à ce jour, le Machine Learning s'impose comme un outil incontournable pour l'évaluation probabiliste des risques et l'atténuation des impacts.

1.7 Diagramme de Gantt du projet

Afin d'assurer le bon déroulement de ce projet, un planning prévisionnel a été établi. Le diagramme de Gantt ci-dessous illustre les différentes phases du projet, de l'étude bibliographique à la rédaction finale, sur une période de plusieurs mois.

Ce planning se décompose en cinq phases principales :

1. **Collecte et préparation des données** : Recherche bibliographique, acquisition des données sismiques, nettoyage et analyse exploratoire
2. **Développement du modèle AI/ML** : Sélection des algorithmes, entraînement, évaluation et optimisation
3. **Conception et développement Front-End** : Design de l'interface, développement de la plateforme web, intégration du modèle
4. **Rédaction du rapport et finalisation** : Rédaction du mémoire, préparation de la soutenance
5. **Livrables et présentation** : Création du poster scientifique, validation finale et soutenance




FIGURE 1.1 – Diagramme de Gantt

1.8 Conclusion

Ce chapitre a permis de définir le cadre théorique de notre étude. Nous avons rappelé les mécanismes fondamentaux des séismes et l'importance cruciale de leur analyse pour la sécurité mondiale. Nous avons également mis en évidence la complémentarité entre la sismologie et le Machine Learning, en passant en revue les approches actuelles de la recherche.

Le diagramme de Gantt a permis de structurer temporellement notre projet, assurant une progression méthodique vers les objectifs fixés. Forts de ces bases, nous allons désormais nous concentrer sur le cœur technique de notre travail : la présentation, l'exploration et la préparation du jeu de données USGS, objet du chapitre suivant.

Chapitre 2

Présentation des données

2.1 Introduction

La qualité et la compréhension des données sont les piliers fondamentaux de tout projet de Machine Learning. Avant de pouvoir entraîner des modèles prédictifs, il est impératif d'acquérir une connaissance approfondie du jeu de données utilisé.

Ce chapitre a pour objectif de présenter le dataset sélectionné, de détailler les variables retenues pour notre analyse, et d'explorer les données à travers une Analyse Exploratoire des Données (EDA). Cette étape nous permettra de dégager les premières tendances, de comprendre la distribution spatiale et temporelle des séismes, et de préparer le terrain pour les phases de prétraitement et de modélisation.

2.2 Présentation du dataset USGS

Pour mener à bien cette étude, nous avons choisi d'utiliser le *USGS Earthquake Database*, un jeu de données public et largement reconnu, disponible sur la plateforme Kaggle. L'*United States Geological Survey* (USGS) est l'agence scientifique de référence aux États-Unis pour la surveillance sismique mondiale.

Ce dataset regroupe l'historique des tremblements de terre enregistrés à l'échelle planétaire. Il est particulièrement pertinent pour notre projet car il offre :

- Une **couverture géographique exhaustive** : Données provenant du monde entier
- Une grande **profondeur temporelle** : Enregistrements sur plusieurs années
- Des mesures **standardisées** de la magnitude et de la profondeur
- Une **fiabilité** garantie par l'expertise de l'USGS

Ces caractéristiques en font une base idéale pour l'entraînement d'algorithmes de Machine Learning.

2.3 Description des variables

Afin d'optimiser les performances de nos modèles et de nous concentrer sur les attributs les plus pertinents pour la prédiction sismique, nous avons opéré une sélection rigoureuse des caractéristiques (features). Le sous-ensemble de données retenu, noté f , se compose des six variables suivantes :

- **Date** : La date de l'événement sismique (format AAAA-MM-JJ). Elle est essentielle pour l'analyse des séries temporelles et l'identification de tendances saisonnières ou annuelles.

- **Time** : L'heure exacte du séisme (au format UTC). Combinée à la date, elle permet une analyse chronologique précise.
- **Latitude** : La coordonnée géographique nord-sud de l'épicentre du séisme (en degrés).
- **Longitude** : La coordonnée géographique est-ouest de l'épicentre (en degrés). Ces deux coordonnées spatiales sont cruciales pour la cartographie et l'analyse géographique des zones à risque.
- **Depth** : La profondeur de l'hypocentre (le point de rupture initial) mesurée en kilomètres. La profondeur influence directement l'intensité des secousses ressenties en surface.
- **Magnitude** : La mesure de l'énergie libérée par le séisme à sa source (généralement sur l'échelle de Richter ou de magnitude de moment). C'est la variable cible principale pour nos tâches de régression et de classification.

2.4 Collecte des données

La collecte et le chargement des données ont été réalisés à l'aide du langage Python et de la bibliothèque *Pandas*, qui est l'outil de référence pour la manipulation de données tabulaires.

Après avoir téléchargé le fichier CSV depuis Kaggle, nous avons chargé l'intégralité du dataset puis procédé à l'extraction des colonnes d'intérêt mentionnées précédemment. De plus, la colonne *Date* a été convertie au format datetime pour faciliter les manipulations temporelles ultérieures.

Extraction et conversion des données (Python/Pandas)

```
import pandas as pd

# Chargement du dataset complet
df = pd.read_csv('earthquake_database.csv')

# Sélection des variables pertinentes pour le projet
f = df[[
    'Date',
    'Time',
    'Latitude',
    'Longitude',
    'Depth',
    'Magnitude'
]]

# Conversion de la colonne Date au format datetime
df['Date'] = pd.to_datetime(df['Date'], errors='coerce')
```

Cette étape de filtrage initiale nous a permis de réduire la dimensionalité du dataset, d'éliminer les variables redondantes ou non pertinentes (comme les codes d'erreur ou les identifiants uniques) et de structurer notre base de travail.

2.5 Analyse exploratoire des données (EDA)

L'Analyse Exploratoire des Données (EDA) est une étape cruciale qui consiste à analyser les données pour résumer leurs caractéristiques principales, souvent à l'aide de méthodes visuelles. L'objectif de l'EDA dans notre projet est triple :

1. Comprendre la distribution de nos variables (notamment la magnitude et la profondeur)
2. Détecter la présence de valeurs aberrantes (outliers) ou de données manquantes

3. Identifier des corrélations potentielles entre les variables géographiques et la magnitude

2.6 Visualisations statistiques

Distribution par profondeur

L'analyse de la répartition des séismes selon leur profondeur révèle une prédominance marquée des séismes superficiels. Comme l'illustre la figure ci-dessous, nous observons que :




FIGURE 2.1 – Répartition des séismes par profondeur

- **79.7%** des séismes sont **superficiels** (profondeur < 70 km)
- **14.6%** sont **intermédiaires** (70 km $\leq$ profondeur ≤ 300 km)
- **5.71%** sont **profonds** (profondeur > 300 km)

Cette distribution est conforme aux connaissances sismologiques établies. La majorité de l'activité sismique se produit dans la croûte terrestre et le manteau supérieur, où les contraintes tectoniques sont les plus importantes.

Distribution des magnitudes par classe

L'analyse de la variable *Magnitude* révèle une distribution fortement asymétrique (biaisée vers la droite), conforme à la **loi de Gutenberg-Richter** en sismologie. Cette loi empirique établit que le nombre de séismes décroît exponentiellement avec l'augmentation de la magnitude.

Distribution des magnitudes par classe




FIGURE 2.2 – Distribution des magnitudes par classe

La grande majorité des séismes enregistrés sont de faible magnitude (entre 2.0 et 4.5), tandis que les séismes de forte magnitude (supérieure à 7.0) sont beaucoup plus rares. Cette observation a des implications importantes pour notre modélisation, car elle introduit un déséquilibre de classes que nous devons prendre en compte.

Relation Profondeur vs Classe de magnitude

L'analyse de la relation entre la profondeur et la classe de magnitude nous permet d'identifier d'éventuelles corrélations entre ces deux variables.

Cette visualisation nous permet d'observer si certaines profondeurs sont associées à des magnitudes particulières, ce qui pourrait constituer un facteur prédictif important.

Profondeur vs Classe de magnitude




FIGURE 2.3 – Profondeur vs Classe de magnitude

2.7 Analyse géographique des séismes

Répartition par région

L'analyse spatiale, basée sur les variables *Latitude* et *Longitude*, permet de visualiser la répartition des épicentres à la surface du globe. Nous avons regroupé les séismes par grandes régions géographiques.

Les résultats montrent que :

- L'**Asie** est la région la plus touchée, suivie de l'**Océanie**
- L'**Amérique du Sud** et l'**Amérique du Nord** présentent également une activité sismique importante
- L'**Europe/Afrique** et l'**Afrique du Sud** sont moins affectées

Densité géographique mondiale

La carte de densité générée met en évidence une concentration très marquée des séismes le long de frontières tectoniques bien connues.

On observe notamment :

Séismes par région




FIGURE 2.4 – Nombre de séismes par région géographique

- La **Ceinture de feu du Pacifique** (Ring of Fire), qui entoure l’océan Pacifique et concentre environ 90% des séismes mondiaux
- La **ceinture alpine** (ou ceinture méditerranéo-himalayenne), qui s’étend de l’Europe du Sud à l’Asie du Sud-Est
- Les **dorsales médio-océaniques**, où les plaques tectoniques s’écartent

Cette répartition géographique confirme que la localisation est un prédicteur indirect mais puissant de l’activité sismique et du risque associé.

Exemple de visualisation interactive

Notre dashboard permet de visualiser les caractéristiques d’un séisme spécifique de manière interactive.

2.8 Conclusion

Ce chapitre nous a permis de faire connaissance avec le dataset USGS et de comprendre la nature des données que nous allons traiter. L’analyse exploratoire a mis en lumière plusieurs

Densité géographique




FIGURE 2.5 – Densité géographique des séismes

Fréquence des séismes par Mois × Heure (UTC)




FIGURE 2.6 – Exemple de visualisation d'un séisme (Magnitude=5.6, Latitude=-44.009, Longitude=-15.978)

caractéristiques fondamentales :

- La prédominance des séismes superficiels (79.7%)
- La distribution logarithmique des magnitudes conforme à la loi de Gutenberg-Richter
- La concentration géographique le long des failles tectoniques majeures
- La variabilité régionale de l'activité sismique

Cependant, cette première exploration a également révélé la présence potentielle de données manquantes et la nécessité de transformer certaines variables (comme la date et les classes de magnitude) pour les rendre exploitables par les algorithmes. Ces constats nous amènent naturellement au chapitre suivant, qui sera consacré au prétraitement rigoureux des données et à l'ingénierie des fonctionnalités (*Feature Engineering*).

Chapitre 3

Prétraitement et Feature Engineering

3.1 Introduction

En Machine Learning, la qualité des données d'entrée détermine directement la performance des modèles prédictifs. C'est ce que résume l'adage bien connu dans le domaine de la Data Science : *"Garbage in, garbage out"* (déchets en entrée, déchets en sortie).

Les données brutes issues du dataset USGS, bien que riches, contiennent souvent du bruit, des valeurs manquantes ou des formats inadaptés aux algorithmes. Ce chapitre détaille les étapes rigoureuses de prétraitement (*Data Preprocessing*) et d'ingénierie des fonctionnalités (*Feature Engineering*) que nous avons appliquées.

L'objectif est de nettoyer le dataset, de transformer les variables et de créer de nouvelles caractéristiques pertinentes afin d'optimiser l'apprentissage de nos modèles.

3.2 Nettoyage des données

Le nettoyage des données constitue la première étape de notre pipeline. Il s'agit d'un processus itératif visant à corriger les incohérences, à uniformiser les formats et à garantir l'intégrité du jeu de données.

Pour ce projet, le nettoyage s'est concentré sur :

- La **cohérence des coordonnées géographiques** : Vérification que les valeurs de latitude sont comprises entre -90° et 90° , et que les longitudes sont entre -180° et 180°
- La **validité des dates** : S'assurer que toutes les dates sont au bon format et chronologiquement cohérentes
- L'**homogénéité des unités de mesure** : Vérifier que la profondeur est bien exprimée en kilomètres et la magnitude sur l'échelle standard
- La **suppression des incohérences** : Élimination des enregistrements physiquement impossibles (magnitudes négatives, profondeurs aberrantes)

3.3 Gestion des valeurs manquantes

Les valeurs manquantes (*missing values*) peuvent biaiser les modèles ou provoquer des erreurs lors de l'entraînement. Après une analyse préliminaire, nous avons constaté que certaines entrées présentaient des valeurs nulles (NaN) sur des colonnes critiques.

Notre stratégie a été la suivante :

- **Suppression** : Les lignes présentant des valeurs manquantes sur les variables cibles ou structurantes (telles que *Magnitude*, *Latitude*, *Longitude* ou *Date*) ont été supprimées, car il

est impossible de prédire ou d'analyser un événement sans ces informations fondamentales.

- **Imputation** : Pour des variables secondaires comme la *Depth* (profondeur), lorsque le taux de données manquantes était faible, nous avons opté pour une imputation par la médiane, afin de ne pas perdre d'observations géographiquement utiles.

Le choix de la médiane plutôt que de la moyenne s'explique par la présence de valeurs extrêmes dans la distribution des profondeurs, qui pourraient fausser la moyenne.

3.4 Suppression des doublons

Lors de l'agrégation de données sismiques provenant de multiples capteurs ou de mises à jour successives de la base USGS, des enregistrements dupliqués peuvent apparaître. Ces doublons faussent la distribution statistique et peuvent surpondérer certains événements lors de l'entraînement.

Nous avons utilisé la fonction `drop_duplicates()` de Pandas pour identifier et supprimer ces entrées redondantes, garantissant ainsi l'unicité de chaque événement sismique dans notre dataset. Cette opération a permis d'éliminer environ X% d'enregistrements en double.

3.5 Traitement des outliers

Le traitement des valeurs aberrantes (*outliers*) dans le domaine de la sismologie requiert une approche nuancée. Contrairement à d'autres domaines où les valeurs extrêmes sont souvent des erreurs de mesure, dans le cas des séismes, une magnitude de 8.5 ou une profondeur de 700 km sont des événements réels et physiquement possibles.

Méthodologie d'identification

Nous avons utilisé plusieurs méthodes pour détecter les outliers :

- **Diagrammes en boîte (boxplots)** : Visualisation de la distribution et identification des valeurs au-delà des moustaches
- **Méthode de l'écart interquartile (IQR)** : Identification des valeurs en dehors de l'intervalle $[Q1 - 1.5 \times IQR; Q3 + 1.5 \times IQR]$
- **Z-score** : Détection des valeurs dont l'écart à la moyenne dépasse 3 écarts-types

Décision de traitement

Plutôt que de supprimer ces événements extrêmes (qui sont souvent les plus destructeurs et donc les plus importants à prédire), nous avons choisi de les conserver. Cependant, pour éviter qu'ils ne déstabilisent les algorithmes sensibles aux échelles (comme la régression linéaire ou les SVM), nous avons appliqué des techniques de :

- **Normalisation** : Mise à l'échelle des variables
- **Transformation logarithmique** : Pour réduire l'impact des valeurs extrêmes
- **Robust Scaling** : Utilisation de la médiane et de l'IQR plutôt que de la moyenne et de l'écart-type

3.6 Transformation des variables

Les algorithmes de Machine Learning basés sur des calculs de distance (KNN, SVM, Réseaux de Neurones) ou d'optimisation par gradient sont très sensibles à l'échelle des variables. Par exemple, la variable *Depth* peut varier de 0 à 700, tandis que la *Magnitude* varie généralement de 1 à 9.

Pour remédier à ce déséquilibre, nous avons appliqué une **standardisation** (Z-score normalization) sur les variables numériques continues :

$$z = \frac{x - \mu}{\sigma} \quad (3.1)$$

où μ est la moyenne et σ l'écart-type de la variable. Cette transformation centre les données autour de 0 avec une variance de 1, permettant à tous les algorithmes de converger plus rapidement et d'accorder une importance équitable à chaque caractéristique.

3.7 Extraction des variables temporelles

La variable *Date* brute (au format YYYY-MM-DD) n'est pas directement exploitable par la plupart des modèles de Machine Learning. Pour permettre au modèle de capturer des potentiels motifs temporels (saisonnalité, cycles annuels), nous avons décomposé la date en plusieurs variables distinctes :

- **Année (Year)** : Pour observer les tendances à long terme
- **Mois (Month)** : Pour détecter une éventuelle saisonnalité
- **Jour du mois (Day)** : Pour des analyses de fréquence plus fines
- **Jour de la semaine (DayOfWeek)** : Pour identifier d'éventuels patterns hebdomadaires
- **Heure (Hour)** : Extraite de la variable *Time*, permettant d'analyser la distribution temporelle des séismes sur une journée

Extraction des features temporelles (Python)

```
# Conversion en datetime et extraction des features
df['Date'] = pd.to_datetime(df['Date'])
df['Year'] = df['Date'].dt.year
df['Month'] = df['Date'].dt.month
df['Day'] = df['Date'].dt.day
df['DayOfWeek'] = df['Date'].dt.dayofweek
df['Hour'] = pd.to_datetime(df['Time'], format='%H:%M:%S').dt.hour
```

3.8 Création de variables dérivées

En plus des variables temporelles, nous avons créé plusieurs variables dérivées pour enrichir notre dataset :

- **Depth ratio** : Ratio entre la profondeur et une profondeur de référence
- **Distance au centre** : Distance entre l'épicentre et le centre géographique de la région
- **Is_deep** : Variable binaire indiquant si le séisme est profond (> 300 km)
- **Lat/Lon bins** : Discrétisation des coordonnées géographiques en zones
- **Region encoding** : Encodage des régions géographiques

3.9 Création des classes de magnitude

Pour répondre à notre objectif de **classification des niveaux de risque**, il est nécessaire de transformer la variable continue *Magnitude* en une variable catégorielle. Nous avons défini des classes de risque basées sur les échelles de classification sismique standard (USGS / Richter) :

- **Moyen** : Magnitude < 5.0
 - Séismes généralement non destructeurs
 - Représentent la majorité des événements
- **Fort** : 5.0 Magnitude < 7.0

- Peuvent causer des dégâts importants dans les zones peuplées
- Nécessitent une attention particulière
- **Majeur** : Magnitude 7.0
- Séismes destructeurs sur de vastes zones
- Potentiel catastrophique élevé

Cette discrétisation, réalisée via la fonction `pd.cut()` de Pandas, nous permet de formuler notre problème non plus comme une simple régression, mais comme un problème de classification supervisée multi-classe, ce qui est souvent plus parlant pour les outils d'aide à la décision.

Création des classes de magnitude (Python)

```
# Définition des bins et des labels
bins = [0, 5.0, 7.0, 10.0]
labels = ['Moyen', 'Fort', 'Majeur']

# Création de la variable catégorielle
df['magnitude_class'] = pd.cut(df['Magnitude'], bins=bins, labels=labels)
```

3.10 Encodage des variables catégorielles

Les algorithmes de Machine Learning ne peuvent pas traiter directement les variables catégorielles textuelles. Nous avons donc appliqué un encodage approprié :

- **Label Encoding** : Pour les variables ordinales (comme les classes de magnitude)
- **One-Hot Encoding** : Pour les variables nominales (comme les régions géographiques)

3.11 Conclusion

Ce chapitre a détaillé le processus complet de transformation de notre jeu de données brut en un dataset propre, structuré et enrichi. Les principales opérations réalisées comprennent :

- Le nettoyage et la validation des données
- La gestion des valeurs manquantes et des doublons
- Le traitement nuancé des outliers spécifiques à la sismologie
- La standardisation des variables numériques
- L'extraction de features temporelles pertinentes
- La création de variables dérivées enrichissantes
- La discrétisation de la magnitude en classes de risque
- L'encodage des variables catégorielles

Grâce à ces transformations, nous disposons désormais d'une base de données robuste et optimisée pour l'apprentissage automatique. Ces données sont maintenant parfaitement formatées pour être ingérées par les algorithmes de Machine Learning.

Le chapitre suivant sera consacré à la sélection, à l'entraînement et à l'évaluation de ces modèles pour la prédiction et la classification des séismes.

Chapitre 4

Modélisation Machine Learning

4.1 Introduction

Ce chapitre constitue le cœur technique de notre projet. Après avoir préparé et enrichi nos données, nous allons maintenant développer et comparer différents modèles de Machine Learning pour répondre à nos deux objectifs principaux :

1. La **classification** des séismes selon leur niveau de risque (Moyen, Fort, Majeur)
2. La **régression** pour la prédiction de la magnitude exacte

Nous présenterons les algorithmes utilisés, la méthodologie d'évaluation, les résultats obtenus et l'analyse comparative des performances.

4.2 Algorithmes utilisés

Pour la classification

Nous avons testé plusieurs algorithmes de classification supervisée :

LightGBM (Light Gradient Boosting Machine)

LightGBM est un framework de gradient boosting développé par Microsoft. Il se distingue par :

- Sa **rapidité d'exécution** grâce à des optimisations spécifiques
- Sa **faible consommation mémoire**
- Sa capacité à gérer de grands volumes de données
- D'excellentes performances sur des données tabulaires

LightGBM utilise une technique de croissance des arbres appelée "Leaf-wise" plutôt que "Level-wise", ce qui lui permet de converger plus rapidement vers l'optimum.

XGBoost (Extreme Gradient Boosting)

XGBoost est l'un des algorithmes les plus populaires en Machine Learning. Ses avantages incluent :

- Une **régularisation intégrée** pour éviter le surapprentissage
- La gestion native des **valeurs manquantes**
- Une **parallélisation** efficace
- De nombreuses options de personnalisation

Random Forest

La Forêt Aléatoire est un algorithme d'ensemble qui combine plusieurs arbres de décision :

- **Robustesse** au surapprentissage
- Facilité d'utilisation et peu de réglages nécessaires
- Bonne performance sur divers types de données
- Interprétabilité via l'importance des variables

Régression Logistique

Bien que simple, la régression logistique sert de modèle de référence (baseline) pour comparer les performances des algorithmes plus complexes.

Pour la régression

Pour la prédiction de magnitude, nous avons utilisé :

- **XGBoost Regressor** : Version régression de XGBoost
- **Random Forest Regressor** : Version régression de Random Forest

4.3 Méthodologie d'évaluation

Division des données

Nous avons divisé notre dataset en deux ensembles :

- **Ensemble d'entraînement** (80%) : Pour apprendre les paramètres du modèle
- **Ensemble de test** (20%) : Pour évaluer les performances sur des données non vues

Cette division aléatoire stratifiée garantit que la distribution des classes est préservée dans les deux ensembles.

Métriques de classification

Pour évaluer les modèles de classification, nous utilisons plusieurs métriques :

- **Accuracy (Précision globale)** : Proportion de prédictions correctes
- **Precision** : Proportion de vrais positifs parmi les prédictions positives
- **Recall (Sensibilité)** : Proportion de vrais positifs détectés
- **F1-Score** : Moyenne harmonique de la precision et du recall

Métriques de régression

Pour la régression, nous utilisons :

- **RMSE (Root Mean Square Error)** : Racine de l'erreur quadratique moyenne
- **MAE (Mean Absolute Error)** : Erreur absolue moyenne
- **R² (Coefficient de détermination)** : Proportion de variance expliquée

4.4 Résultats de la classification

Comparaison des modèles

Les résultats obtenus sont présentés dans le tableau comparatif ci-dessous :

TABLE 4.1 – Performance comparative des modèles de classification

Modèle	Accuracy	Precision	Recall	F1-Score
LightGBM	97.99%	97.96%	97.99%	0.9793
XGBoost	97.31%	97.29%	97.31%	0.9716
Random Forest	93.44%	92.79%	93.44%	0.9269
Logistic Regression	92.08%	95.13%	92.08%	0.9296

Comparaison des modèles ML

🏆 Meilleur modèle

LightGBM

✅ Accuracy

98.0 %

📊 F1 (weighted)

0.9793

🎯 Precision

0.9796

Tableau comparatif

	Modèle	Accuracy	Precision	Recall	F1
0	LightGBM	97.99%	97.96%	97.99%	0.9793
1	XGBoost	97.31%	97.29%	97.31%	0.9716
2	RandomForest	93.44%	92.79%	93.44%	0.9269
3	LogisticRegression	92.08%	95.13%	92.08%	0.9296

FIGURE 4.1 – Comparaison visuelle des métriques par modèle

Analyse des résultats

LightGBM se distingue comme le meilleur modèle avec des performances exceptionnelles :

- **Accuracy : 97.99%** : Près de 98 prédictions correctes sur 100
- **F1-Score (weighted) : 0.9793** : Excellent équilibre entre precision et recall
- **Precision : 97.96%** : Très peu de faux positifs
- **Recall : 97.99%** : Détection quasi-totale des vrais positifs

XGBoost arrive en deuxième position avec 97.31% d'accuracy, confirmant la pertinence des méthodes de gradient boosting pour ce type de problème.

Random Forest obtient 93.44% d'accuracy, une performance honorable mais inférieure aux méthodes de boosting.

La Régression Logistique, avec 92.08%, sert de référence et montre que même un modèle linéaire simple peut obtenir des résultats décent, bien que nettement inférieurs aux méthodes ensemblistes.

Matrice de confusion - LightGBM

La matrice de confusion du modèle LightGBM nous permet d'analyser plus finement les erreurs de classification :

L'analyse de cette matrice révèle :

- **Classe "Fort"** : 382 prédictions correctes, seulement 78 confondues avec "Moyen"
- **Classe "Moyen"** : 4206 prédictions correctes, seulement 16 confondues avec "Fort"
- Très peu d'erreurs de classification entre classes adjacentes

Matrice de confusion — LightGBM

Confusion Matrix — LightGBM



FIGURE 4.2 – Matrice de confusion du modèle LightGBM

Ces résultats confirment l'excellente capacité discriminative du modèle LightGBM.

4.5 Résultats de la régression

Prédiction de magnitude avec XGBoost Regressor

Pour la tâche de régression, le modèle XGBoost Regressor a été entraîné sur un échantillon de 1000 séismes. Les résultats sont présentés ci-dessous :

Réel vs Prédit (XGBoost Regressor, n=1000)




FIGURE 4.3 – Valeurs réelles vs prédites (XGBoost Regressor, n=1000)

L'analyse de ce graphique montre :

- Une **forte corrélation** entre les valeurs réelles et prédites
- Les points sont majoritairement alignés sur la diagonale ($y=x$)
- Quelques écarts pour les magnitudes extrêmes, ce qui est attendu

Distribution des résidus

L'analyse des résidus (différence entre valeurs réelles et prédites) permet d'évaluer la qualité du modèle :




FIGURE 4.4 – Distribution des résidus de prédiction

Nous observons que :

- La distribution est **centrée autour de zéro**, indiquant l'absence de biais systématique
- La majorité des résidus sont compris entre -0.5 et +0.5
- Quelques valeurs extrêmes correspondent aux séismes de très forte magnitude

4.6 Importance des variables

L'analyse de l'importance des variables (Feature Importance) est cruciale pour comprendre quels facteurs influencent le plus les prédictions du modèle.

Classement des variables les plus importantes

1. **Depth ratio** : Le ratio de profondeur est le facteur le plus influent, avec une importance supérieure à 3500
2. **Depth** : La profondeur absolue du séisme arrive en deuxième position
3. **Year** : L'année du séisme montre une influence significative
4. **Distance center** : La distance au centre géographique
5. **Day** : Le jour du mois
6. **Latitude** : La coordonnée nord-sud
7. **Hour** : L'heure du séisme
8. **Longitude** : La coordonnée est-ouest




FIGURE 4.5 – Importance des variables dans le modèle LightGBM

9. **Month** : Le mois de l'année

10. **Region_enc** : La région encodée

Interprétation des résultats

Ces résultats sont cohérents avec les connaissances sismologiques :

- La **profondeur** est un facteur déterminant de l'intensité des secousses en surface
- La **localisation géographique** (latitude, longitude, région) influence le type de séisme
- Les variables **temporelles** (année, mois, jour, heure) peuvent révéler des patterns saisonniers ou cycliques

4.7 Visualisation SHAP

Pour approfondir l'interprétabilité du modèle, nous avons utilisé les valeurs SHAP (SHapley Additive exPlanations) :

Cette visualisation montre l'impact de chaque variable sur les prédictions, avec :

- Les couleurs indiquant la valeur de la variable (rouge = élevée, bleu = faible)
- La position horizontale montrant l'impact sur la prédiction

4.8 Conclusion

Ce chapitre a présenté de manière détaillée la modélisation Machine Learning appliquée à notre problème de prédiction sismique. Les principaux enseignements sont :

- **LightGBM** est le meilleur modèle pour la classification, avec une accuracy de 97.99%
- **XGBoost Regressor** obtient d'excellentes performances pour la prédiction de magnitude
- Les variables de **profondeur** et de **localisation** sont les plus influentes
- Les modèles développés sont à la fois performants et interprétables

Comparaison des métriques par modèle




FIGURE 4.6 – Valeurs SHAP pour l’interprétabilité du modèle

Ces résultats valident l’approche Machine Learning pour l’analyse sismique et ouvrent la voie à des applications concrètes. Le chapitre suivant se concentrera sur l’interprétabilité approfondie des modèles et la présentation du dashboard interactif.

Chapitre 5

Interprétabilité et Dashboard Interactif

5.1 Introduction

Après avoir développé et évalué nos modèles de Machine Learning, il est essentiel de les rendre interprétables et accessibles aux utilisateurs. Ce chapitre aborde deux aspects complémentaires :

1. L'**interprétabilité des modèles** : Comprendre comment le modèle prend ses décisions
2. Le **dashboard interactif** : Mettre à disposition un outil pratique pour les utilisateurs

5.2 Interprétabilité des modèles

Pourquoi l'interprétabilité est-elle importante ?

Dans le domaine de la sismologie et de la gestion des risques, il ne suffit pas d'avoir un modèle performant. Il est crucial de comprendre :

- **Pourquoi** le modèle a fait telle ou telle prédiction
- **Quelles variables** ont le plus influencé la décision
- **Comment** les différentes features interagissent entre elles

Cette transparence est essentielle pour :

- Gagner la **confiance** des utilisateurs et des décideurs
- Valider la **cohérence** des prédictions avec les connaissances sismologiques
- Identifier d'éventuels **biais** ou limitations du modèle

Méthodes d'interprétabilité utilisées

Feature Importance

Comme nous l'avons vu au chapitre précédent, l'importance des variables nous indique quelles features contribuent le plus aux prédictions du modèle.

SHAP Values

Les valeurs SHAP (SHapley Additive exPlanations) sont basées sur la théorie des jeux coopératifs et permettent de :

- Attribuer à chaque variable une **contribution** à la prédiction
- Visualiser l'**impact** positif ou négatif de chaque feature

- Comprendre les **interactions** entre variables

Analyse des prédictions individuelles

Pour un séisme donné, nous pouvons décomposer la prédiction du modèle et comprendre le rôle de chaque variable.

5.3 Dashboard Interactif

Objectifs du dashboard

Le dashboard interactif a été développé pour rendre les modèles de Machine Learning accessibles aux utilisateurs non-experts. Ses objectifs sont :

1. Permettre la **saisie intuitive** des paramètres d'un séisme
2. Fournir des **prédictions en temps réel**
3. Offrir des **visualisations claires** des résultats
4. Faciliter l'**aide à la décision** pour les professionnels

Fonctionnalités principales

Interface de prédiction

L'utilisateur peut saisir les paramètres suivants :

- **Latitude** : Coordonnée nord-sud de l'épicentre
- **Longitude** : Coordonnée est-ouest de l'épicentre
- **Profondeur (Depth)** : Profondeur du foyer en kilomètres
- **Année (Year)** : Année du séisme
- **Mois (Month)** : Mois de l'événement
- **Jour (Day)** : Jour du mois
- **Heure (Hour)** : Heure de l'événement
- **Type** : Type d'événement sismique

Visualisations interactives

Le dashboard propose plusieurs visualisations :

- **Carte géographique** : Position de l'épicentre sur une carte interactive
- **Distribution des magnitudes** : Histogramme montrant la répartition historique
- **Analyse temporelle** : Évolution de l'activité sismique dans le temps
- **Comparaison des modèles** : Performance comparative des différents algorithmes

Résultats de prédiction

Après saisie des paramètres et clic sur le bouton "Predict", le dashboard affiche :

- La **magnitude prédite** (valeur continue)
- La **classe de risque** (Moyen, Fort, ou Majeur)
- Le **niveau de confiance** du modèle
- Les **facteurs influents** pour cette prédiction spécifique




FIGURE 5.1 – Tableau de bord principal




FIGURE 5.2 – Paramètres temporels et résultats


LOCALISATION DE L'ÉVÉNEMENT

FIGURE 5.3 – Carte de localisation

Exemple d'utilisation

Prenons l'exemple d'un séisme aux coordonnées suivantes :

- Latitude : 35.00°
- Longitude : 139.00° (région de Tokyo, Japon)
- Profondeur : 50 km
- Date : 15 mai 2024, 12h00
- Type : Earthquake

Le modèle prédit :

- **Magnitude prédite** : Environ 6.0
- **Classe de risque** : **Fort** (car $5.0 \leq M < 7.0$)

Cette prédiction est cohérente avec l'activité sismique historique de cette région située sur la Ceinture de feu du Pacifique.

Technologies utilisées

Le dashboard a été développé en utilisant :

- **Streamlit** ou **Dash** : Framework Python pour les applications web interactives
- **Plotly** : Bibliothèque de visualisation interactive
- **Pandas** : Traitement et manipulation des données
- **Scikit-learn** : Chargement et utilisation des modèles entraînés

Avantages du dashboard

- **Accessibilité** : Interface intuitive ne nécessitant pas de compétences en programmation
- **Rapidité** : Prédictions en temps réel
- **Interactivité** : Possibilité de tester différents scénarios
- **Visualisation** : Représentations graphiques claires des résultats
- **Déploiement facile** : Accessible via un navigateur web

5.4 Limites et perspectives d'amélioration

Limites actuelles

Malgré les performances encourageantes de nos modèles, plusieurs limites doivent être reconnues :

- **Prédiction déterministe impossible** : Nous ne pouvons pas prédire exactement quand et où aura lieu un séisme
- **Biais de données** : Certaines régions sont mieux instrumentées que d'autres
- **Variables manquantes** : D'autres facteurs pourraient améliorer les prédictions (contraintes tectoniques, historique sismique local)
- **Généralisation** : Les modèles peuvent être moins performants dans des régions peu représentées dans les données d'entraînement

Perspectives d'amélioration

Plusieurs pistes pourraient améliorer ce travail :

1. **Intégration de données en temps réel** : Connexion directe aux flux de données de l'USGS
2. **Deep Learning** : Utilisation de réseaux de neurones profonds (CNN, LSTM) pour capturer des patterns complexes

3. **Données additionnelles** : Intégration de données géologiques, de contraintes tectoniques, d'historiques sismiques locaux
4. **Prédiction de répliques** : Développement de modèles spécifiques pour prédire les répliques après un séisme majeur
5. **Extension aux tsunamis** : Prédiction du risque de tsunami suite à un séisme sous-marin
6. **Déploiement à grande échelle** : Intégration dans des systèmes d'alerte précoce

5.5 Conclusion

Ce chapitre a présenté l'interprétabilité des modèles développés et le dashboard interactif qui rend ces modèles accessibles aux utilisateurs.

Les principales contributions sont :

- Une **compréhension approfondie** des facteurs influençant les prédictions
- Un **outil pratique** pour l'aide à la décision
- Une **interface intuitive** permettant à des non-experts d'utiliser les modèles
- Des **visualisations claires** facilitant l'interprétation des résultats

Ce dashboard constitue une contribution concrète à la gestion des risques sismiques et ouvre la voie à des applications opérationnelles.

Conclusion Générale

Ce projet de fin d'études a démontré le potentiel du Machine Learning pour l'analyse et la prédiction des tremblements de terre. À travers une démarche méthodologique rigoureuse, nous avons exploité le dataset USGS pour développer des modèles prédictifs performants.

Principales réalisations

Au cours de ce travail, nous avons :

1. **Analysé en profondeur** le dataset USGS Earthquake Database, révélant des patterns géographiques et temporels significatifs
2. **Développé des modèles de classification** performants, avec le modèle LightGBM atteignant une accuracy exceptionnelle de **97.99%**
3. **Créé des modèles de régression** pour la prédiction de magnitude, avec le XGBoost Regressor montrant d'excellentes performances
4. **Identifié les variables influentes** : La profondeur (depth), le ratio de profondeur (depth_ratio) et la distance au centre géographique sont les facteurs les plus déterminants
5. **Conçu un dashboard interactif** permettant aux utilisateurs de saisir des paramètres et d'obtenir des prédictions en temps réel
6. **Assuré l'interprétabilité** des modèles grâce aux analyses SHAP et Feature Importance

Apports du projet

Ce travail apporte plusieurs contributions :

- **Contribution scientifique** : Validation de l'efficacité des méthodes de gradient boosting (LightGBM, XGBoost) pour la classification sismique
- **Contribution méthodologique** : Pipeline complet de Data Science, de l'EDA au déploiement
- **Contribution pratique** : Dashboard interactif opérationnel pour l'aide à la décision
- **Contribution pédagogique** : Documentation complète et reproductibilité du travail

Perspectives futures

Plusieurs axes d'amélioration et de développement peuvent être envisagés :

- **Intégration de données en temps réel** : Connexion aux flux live de l'USGS pour des prédictions actualisées
- **Deep Learning** : Exploration de réseaux de neurones profonds (LSTM, CNN) pour capturer des patterns temporels et spatiaux complexes

- **Données enrichies** : Intégration de données géologiques, de contraintes tectoniques et d'historiques sismiques locaux
- **Prédiction de répliques** : Développement de modèles spécifiques pour anticiper les répliques après un séisme majeur
- **Extension aux tsunamis** : Prédiction du risque de tsunami suite à un séisme sous-marin
- **Déploiement opérationnel** : Intégration dans des systèmes d'alerte précoce pour la protection civile
- **Amélioration du dashboard** : Ajout de fonctionnalités avancées (export de rapports, alertes automatiques, multi-utilisateurs)

Mot de la fin

Ce projet a été une expérience enrichissante qui nous a permis de mettre en pratique nos connaissances en Machine Learning, en analyse de données et en développement d'applications. Il démontre que l'Intelligence Artificielle peut apporter une contribution significative à la gestion des risques naturels, même si la prédiction exacte des séismes reste un défi scientifique non résolu.

Nous espérons que ce travail pourra servir de base à des développements futurs et contribuer, même modestement, à l'amélioration de la prévention et de la gestion des risques sismiques pour la protection des populations.

Bibliographie

- **USGS Earthquake Database.** <https://www.kaggle.com/datasets/usgs/earthquake-database>
- **Chen, T., & Guestrin, C.** (2016). XGBoost : A Scalable Tree Boosting System. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785-794).
- **Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... & Liu, T.Y.** (2017). LightGBM : A Highly Efficient Gradient Boosting Decision Tree. In Advances in Neural Information Processing Systems (pp. 3146-3154).
- **Lundberg, S.M., & Lee, S.I.** (2017). A Unified Approach to Interpreting Model Predictions. In Advances in Neural Information Processing Systems (pp. 4765-4774).
- **Breiman, L.** (2001). Random Forests. Machine Learning, 45(1), 5-32.
- **Gutenberg, B., & Richter, C.F.** (1944). Frequency of Earthquakes in California. Bulletin of the Seismological Society of America, 34(4), 185-188.
- **Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Vanderplas, J.** (2011). Scikit-learn : Machine Learning in Python. Journal of Machine Learning Research, 12(Oct), 2825-2830.
- **McKinney, W.** (2010). Data Structures for Statistical Computing in Python. In Proceedings of the 9th Python in Science Conference (pp. 51-56).
- **USGS.** (2023). Earthquake Hazards Program. <https://earthquake.usgs.gov/>
- **Kaggle.** (2023). USGS Earthquake Database. <https://www.kaggle.com/datasets/usgs/earthquake-database>